

Libro de Códigos

Establecimientos educativos de nivel diversificado — 22 departamentos de Guatemala

Proyecto 1 · CC3084 Data Science · Universidad del Valle de Guatemala · Semestre II 2026

Campo	Valor
Descripción	Establecimientos educativos de Guatemala que llegan hasta el nivel diversificado (NIVEL ESCOLAR: DIVERSIFICADO), de los 22 departamentos del país.
Fuente de los datos	MINEDUC — http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/
Fecha de extracción	Julio 2026
Fecha de limpieza	Julio 2026
Versión del conjunto limpio	v1.0
Archivo limpio	Data/limpio/establecimientos_diversificado_limpio.csv
Codificación	UTF-8 con BOM
Registros	9,706
Variables	22
Cobertura	22 departamentos de Guatemala (país completo)
Llave primaria	CODIGO (única, sin repetidos)

Origen de los datos crudos. Los datos vinieron en 22 archivos CSV (uno por departamento), en dos estructuras: Grupo A (11 archivos, 18 columnas, con SUPERVISOR y DIRECTOR separados y una columna vacía) y Grupo B (11 archivos, 16 columnas, con SUPERVISOR_DIRECTOR fusionado y un desplazamiento de columnas hacia DEPARTAMENTAL). La limpieza los unificó en un solo conjunto. El proceso reproducible está en `code/limpieza.ipynb` (usa `code/limpieza_lib.py`).

Diccionario de variables

Para cada variable: descripción, tipo, dominio permitido, valores posibles, tratamiento aplicado y porcentaje de faltantes en el conjunto limpio.

1. CODIGO

Tipo de dato	texto (identificador)
Dominio permitido	Patrón NN-NN-NNNN-NN
Valores posibles	9,706 valores únicos (uno por registro).
Tratamiento aplicado	Ninguno; se verificó formato (100% conforme) y unicidad. Es la llave primaria.
Faltantes	0%

2. DISTRITO

Tipo de dato	texto (código)
Dominio permitido	NN-NN-NNNN o NN-NNN
Valores posibles	1,590 códigos.
Tratamiento aplicado	Se conservaron los dos formatos válidos; los truncados imposibles (17-, 10-) se pasaron a NA (3 registros).
Faltantes	3.27%

3. DEPARTAMENTO

Tipo de dato	categorico
Dominio permitido	Los 22 departamentos oficiales de Guatemala.
Valores posibles	ALTA VERAPAZ, BAJA VERAPAZ, CHIMALTENANGO, CHIQUIMULA, EL PROGRESO, ESCUINTLA, GUATEMALA, HUEHUETENANGO, IZABAL, JALAPA, JUTIAPA, PETEN, QUETZALTENANGO, QUICHE, RETALHULEU, SACATEPEQUEZ, SAN MARCOS, SANTA ROSA, SOLOLA, SUCHITEPEQUEZ, TOTONICAPAN, ZACAPA.
Tratamiento aplicado	Mayúsculas y sin tildes (criterio unificado).
Faltantes	0%

4. MUNICIPIO

Tipo de dato	categorico
Dominio permitido	Municipios del departamento correspondiente.
Valores posibles	505 municipios.
Tratamiento aplicado	Normalización de texto (mayúsculas, espacios, invisibles).
Faltantes	0%

5. ESTABLECIMIENTO

Tipo de dato	texto libre
Dominio permitido	Texto.
Valores posibles	5,552 nombres únicos.
Tratamiento aplicado	Mayúsculas, eliminación de espacios dobles e invisibles, corrección de acento grave invertido (Ö→Ó). No se alteraron los nombres oficiales.
Faltantes	1.13%

6. DIRECCION

Tipo de dato	texto libre
Dominio permitido	Texto.
Valores posibles	5,490 direcciones únicas.
Tratamiento aplicado	Normalización de texto. En el Grupo B algunos registros traían datos mezclados; solo se corrigió con evidencia suficiente y se conservaron nulos cuando no fue posible recuperar el dato.
Faltantes	6.62%

7. TELEFONO

Tipo de dato	texto (respaldo)
Dominio permitido	Texto con dígitos y separadores.
Valores posibles	—
Tratamiento aplicado	Normalización de texto. Se conserva como respaldo; los valores usables se derivan en TELEFONO_1/TELEFONO_2.
Faltantes	7.10%

8. TELEFONO_1 (derivada)

Tipo de dato	texto (8 dígitos)
Dominio permitido	Exactamente 8 dígitos (estándar de Guatemala).
Valores posibles	—
Tratamiento aplicado	Se separó TELEFONO por sus separadores (guion, espacio, coma) y se tomó el primer número de 8 dígitos.
Faltantes	7.68%

9. TELEFONO_2 (derivada)

Tipo de dato	texto (8 dígitos)
Dominio permitido	Exactamente 8 dígitos.
Valores posibles	—
Tratamiento aplicado	Igual que TELEFONO_1, tomando el segundo número válido.
Faltantes	99.11% (solo con 2 teléfonos)

10. N_TELEFONOS (derivada)

Tipo de dato	entero
Dominio permitido	0, 1, 2, 3.
Valores posibles	—
Tratamiento aplicado	Cantidad de números válidos (8 dígitos). Permite validar formato y detectar registros sin teléfono válido.
Faltantes	0%

11. SUPERVISOR_DIRECTOR

Tipo de dato	texto libre
Dominio permitido	Texto (nombres de persona).
Valores posibles	6,136 valores únicos.

Tratamiento aplicado	En el Grupo A se fusionaron SUPERVISOR y DIRECTOR (separados por espacio) para uniformar con el Grupo B. El marcador '----' se pasó a NA. No se separaron los dos nombres en B por falta de delimitador confiable.
Faltantes	5.75%

12. NIVEL

Tipo de dato	categórico (constante)
Dominio permitido	DIVERSIFICADO
Valores posibles	DIVERSIFICADO (único valor).
Tratamiento aplicado	Se conserva como constante documentada; confirma el filtro de extracción.
Faltantes	0%

13. SECTOR

Tipo de dato	categórico
Dominio permitido	OFICIAL, PRIVADO, COOPERATIVA, MUNICIPAL.
Valores posibles	4 valores.
Tratamiento aplicado	Mayúsculas, sin tildes.
Faltantes	0%

14. AREA

Tipo de dato	categórico
Dominio permitido	URBANA, RURAL.
Valores posibles	2 valores.
Tratamiento aplicado	Mayúsculas, sin tildes.
Faltantes	0.02%

15. STATUS

Tipo de dato	categórico
Dominio permitido	ABIERTA, CERRADA TEMPORALMENTE, CERRADA DEFINITIVAMENTE, TEMPORAL NOMBRAMIENTO, TEMPORAL TITULOS.
Valores posibles	5 valores.
Tratamiento aplicado	En el Grupo B se recuperó desde DEPARTAMENTAL por el desplazamiento de columnas; mayúsculas, sin tildes.
Faltantes	0%

16. MODALIDAD

Tipo de dato	categórico
Dominio permitido	MONOLINGUE, BILINGUE.
Valores posibles	2 valores.
Tratamiento aplicado	Recuperación desde DEPARTAMENTAL (Grupo B); mayúsculas, sin tildes.
Faltantes	0%

17. JORNADA

Tipo de dato	categórico
---------------------	------------

Dominio permitido	MATUTINA, VESPERTINA, DOBLE, NOCTURNA, INTERMEDIA, SIN JORNADA.
Valores posibles	6 valores.
Tratamiento aplicado	Recuperación desde DEPARTAMENTAL (Grupo B); mayúsculas, sin tildes.
Faltantes	0%

18. PLAN

Tipo de dato	categorico
Dominio permitido	DIARIO(REGULAR), FIN DE SEMANA, SABATINO, DOMINICAL, MIXTO, IRREGULAR, A DISTANCIA, VIRTUAL A DISTANCIA, SEMIPRESENCIAL, SEMIPRESENCIAL (FIN DE SEMANA), SEMIPRESENCIAL (UN DIA A LA SEMANA), SEMIPRESENCIAL (DOS DIAS A LA SEMANA).
Valores posibles	12 valores.
Tratamiento aplicado	Recuperación desde DEPARTAMENTAL (Grupo B); mayúsculas, sin tildes.
Faltantes	0.02%

19. DEPARTAMENTAL

Tipo de dato	categorico
Dominio permitido	Los 22 departamentos, con subdivisiones legítimas: GUATEMALA (NORTE, SUR, ORIENTE, OCCIDENTE) y QUICHE (QUICHE, QUICHE NORTE). 26 jurisdicciones.
Valores posibles	26 valores.
Tratamiento aplicado	En el Grupo B se extrajo la jurisdicción del texto contaminado por el desplazamiento; mayúsculas, sin tildes.
Faltantes	0%

20. GRUPO_ORIGEN (derivada)

Tipo de dato	categorico
Dominio permitido	A, B.
Valores posibles	2 valores.
Tratamiento aplicado	Grupo estructural del archivo crudo de origen. Trazabilidad de origen y decisiones de limpieza.
Faltantes	0%

21. ES_POSIBLE_DUPLICADO (derivada)

Tipo de dato	booleano
Dominio permitido	True, False.
Valores posibles	2 valores.
Tratamiento aplicado	Dos registros del mismo depto y municipio con nombre casi idéntico (RapidFuzz ≥ 90), misma dirección (≥ 90) o teléfono, y coincidencia en JORNADA, PLAN, SECTOR, AREA. Marca 1,724 filas (1,030 pares). No se eliminaron: CODIGO es llave única. Detalle en Data/limpio/posibles_duplicados.csv.
Faltantes	0%

22. REVISAR_MANUAL (derivada)

Tipo de dato	texto
Dominio permitido	Texto o NA.
Valores posibles	—

Tratamiento aplicado	Marca los 4 registros del Grupo B cuyo desplazamiento dejó texto sin asignar tras el parseo. Se conservan con la jurisdicción ya extraída y una nota para revisión.
Faltantes	99.96% (solo 4 registros)

Variables derivadas (resumen)

Variable	Se creó porque	Cómo se calculó	Utilidad
TELEFONO_1, TELEFONO_2	El campo original mezclaba varios teléfonos	Separando TELEFONO por sus separadores y validando 8 dígitos	Un teléfono por columna, validable
N_TELEFONOS	Se necesita saber cuántos teléfonos válidos hay	Conteo de números de 8 dígitos por registro	Validación y control de calidad
GRUPO_ORIGEN	Los datos vinieron en dos estructuras	Etiqueta A/B según el archivo de origen	Trazabilidad
ES_POSIBLE_DUPLICADO	La guía exige detectar duplicados parciales	Similitud de cadenas (RapidFuzz) + coincidencia de campos clave	Revisión de duplicados sin borrado automático
REVISAR_MANUAL	Algunos casos no se resuelven sin criterio humano	Marca puesta durante la reparación del desplazamiento	Auditoría y revisión manual

Reproducibilidad

Todo el proceso es reproducible desde la raíz del repositorio:

```
pip install pandas numpy rapidfuzz unidecode nbformat nbconvert ipykernel  
python -m nbconvert --to notebook --execute --inplace code/limpieza.ipynb
```

Genera Data/limpio/establecimientos_diversificado_limpio.csv y los reportes de apoyo (registro_transformaciones.csv, informe_calidad.csv, posibles_duplicados.csv).