

Avances del proyecto 1

Link Repo: --> [Repo](#) <--

DIAGNÓSTICO DEL CONJUNTO DE DATOS

Análisis del estado inicial de los datos

Se realizó el análisis del conjunto de datos correspondiente a los establecimientos educativos hasta nivel diversificado de los 22 departamentos de Guatemala. Durante la revisión se identificó que los archivos están divididos en dos grupos con estructuras diferentes, por lo que el diagnóstico considera ambos casos.

A. Número de registros y variables

El conjunto de datos está conformado por 22 archivos, distribuidos en dos grupos:

- Grupo A: 11 archivos con 4,033 registros y 18 variables.
- Grupo B: 11 archivos con 5,673 registros y 16 variables.

En total se analizaron 9,706 registros correspondientes a los 22 departamentos de Guatemala.

B. Tipo de dato de cada variable

Grupo A (18 variables)

Variable	Tipo de dato	Descripción
----------	--------------	-------------

CODIGO	Texto	Identificador
Columna sin nombre	Texto	Vacía (0 valores)
DISTRITO	Texto	Código
DEPARTAMENTO	Texto	Categorico
MUNICIPIO	Texto	Categorico
ESTABLECIMIENTO	Texto	Texto libre
DIRECCION	Texto	Texto libre
TELEFONO	Texto	Numérico no convertible a entero (puede contener más de un número)
SUPERVISOR	Texto	Nombre de persona
DIRECTOR	Texto	Nombre de persona
NIVEL	Texto	Categorico constante
SECTOR	Texto	Categorico

AREA	Texto	Categorico
STATUS	Texto	Categorico
MODALIDAD	Texto	Categorico
JORNADA	Texto	Categorico
PLAN	Texto	Categorico
DEPARTAMENTAL	Texto	Categorico

Grupo B (16 variables)

Variable	Tipo de dato	Descripción
CODIGO	Texto	Identificador
DISTRITO	Texto	Código
DEPARTAMENTO	Texto	Categorico
MUNICIPIO	Texto	Categorico

ESTABLECIMIENTO	Texto	Texto libre
DIRECCION	Texto	Texto libre
TELEFONO	Texto	Numérico no convertible a entero (puede contener más de un número)
SUPERVISOR_DIRECTOR	Texto	Texto libre (dos nombres concatenados)
NIVEL	Texto	Categórico constante
SECTOR	Texto	Categórico
AREA	Texto	Categórico
STATUS	Texto	Categórico
MODALIDAD	Texto	Categórico
JORNADA	Texto	Categórico
PLAN	Texto	Categórico
DEPARTAMENTAL	Texto	Categórico (contaminado por desplazamiento de columnas)

Nota: Todas las variables fueron leídas como **texto (string)**. La variable **TELEFONO** permanece como texto porque algunos registros contienen más de un número telefónico. Además, el **Grupo B** no incluye la columna sin nombre del Grupo A y fusiona las variables **SUPERVISOR** y **DIRECTOR** en una sola columna (**SUPERVISOR_DIRECTOR**).

C. Cantidad y porcentaje de valores faltantes por variable

Grupo A (4,033 registros)

Variable	Cantidad de valores faltantes	Porcentaje
Columna sin nombre	4,033	100.00 %
DIRECTOR	475	11.78 %
TELEFONO	295	7.31 %
SUPERVISOR	118	2.93 %
DISTRITO	115	2.85 %
DIRECCION	39	0.97 %

ESTABLECIMIENTO	1	0.02 %
CODIGO	0	0.00 %
DEPARTAMENTO	0	0.00 %
MUNICIPIO	0	0.00 %
NIVEL	0	0.00 %
SECTOR	0	0.00 %
AREA	0	0.00 %
STATUS	0	0.00 %
MODALIDAD	0	0.00 %
JORNADA	0	0.00 %
PLAN	0	0.00 %
DEPARTAMENTAL	0	0.00 %

Grupo B (5,673 registros)

Variable	Cantidad de valores faltantes	Porcentaje
PLAN	817	14.40 %
JORNADA	638	11.25 %
DIRECCION	600	10.58 %
SUPERVISOR_DIRECTOR	449	7.91 %
TELEFONO	394	6.95 %
DISTRITO	199	3.51 %
ESTABLECIMIENTO	109	1.92 %
STATUS	55	0.97 %
MODALIDAD	55	0.97 %
AREA	2	0.04 %

CODIGO	0	0.00 %
DEPARTAMENTO	0	0.00 %
MUNICIPIO	0	0.00 %
NIVEL	0	0.00 %
SECTOR	0	0.00 %
DEPARTAMENTAL	0	0.00 %

Datos puntuales:

- ESTABLECIMIENTO faltante en A: CODIGO 11-05-1304-46
 - AREA faltante en B: CODIGO 16-01-0982-46 y 05-02-0065-46
 - De los faltantes de B, 1565 no son perdida real (PLAN 817 + JORNADA 638 + STATUS 55 + MODALIDAD 55): estan dentro de DEPARTAMENTAL, ver inciso 6.
 - Faltantes disfrazados: 3 registros de DIRECTOR en A tienen "----" en vez de vacio, no se cuentan como nulos arriba.
 - Concentracion: en A los faltantes se reparten parejo entre departamentos.
- En B, guatemala es el que mas aporta por ser el archivo mas grande, y huehuetenango tiene 242 de las 600 direcciones vacias.

D. Cantidad de valores únicos

Grupo A

Variable	Cantidad de valores únicos
CODIGO	4,033
Columna sin nombre	0
DISTRITO	753
DEPARTAMENTO	11
MUNICIPIO	182
ESTABLECIMIENTO	2,102
DIRECCION	2,448
TELEFONO	2,339

SUPERVISOR	598
DIRECTOR	2,065
NIVEL	1
SECTOR	4
AREA	2
STATUS	5
MODALIDAD	2
JORNADA	6
PLAN	12
DEPARTAMENTAL	12

Grupo B

Variable	Cantidad de valores únicos
----------	----------------------------

CODIGO	5,673
DISTRITO	841
DEPARTAMENTO	11
MUNICIPIO	331
ESTABLECIMIENTO	3,489
DIRECCION	3,093
TELEFONO	3,207
SUPERVISOR_DIRECTOR	3,553
NIVEL	1
SECTOR	4
AREA	2
STATUS	3

MODALIDAD	2
JORNADA	5
PLAN	5
DEPARTAMENTAL	120

La variable CODIGO presenta un valor único por cada registro en ambos grupos, por lo que funciona como llave primaria. La variable NIVEL mantiene un único valor (DIVERSIFICADO), indicando que es constante. En el Grupo B, DEPARTAMENTAL presenta 120 valores únicos, cuando deberían existir únicamente 14, lo que evidencia inconsistencias ocasionadas por el desplazamiento de información entre columnas.

E. Cantidad de registros duplicados exactos

No se encontraron registros duplicados exactos en ninguno de los archivos analizados.

Asimismo, no existen códigos repetidos, por lo que la variable CODIGO identifica correctamente cada establecimiento.

F. Variables con valores fuera de dominio o inconsistentes

El principal problema identificado corresponde al Grupo B, donde la información de las variables STATUS, MODALIDAD, JORNADA y PLAN quedó desplazada hacia la columna DEPARTAMENTAL, generando inconsistencias y valores faltantes aparentes.

También se encontraron los siguientes problemas:

- Teléfonos con más de un número o con longitud incorrecta.
- Valores “—” en la variable DIRECTOR, utilizados como marcador en lugar de un valor nulo.
- La variable SUPERVISOR_DIRECTOR contiene dos nombres concatenados sin un separador.
- La variable PLAN presenta categorías fragmentadas.

G. Variables con formatos inconsistentes

Se detectaron diversas inconsistencias en los formatos de los datos:

- La variable DISTRITO utiliza dos formatos diferentes.
- La variable TELEFONO presenta distintos separadores entre números telefónicos.
- Existen diferencias en el uso de tildes entre DEPARTAMENTO y DEPARTAMENTAL.
- Los archivos utilizan diferentes codificaciones (UTF-8 con BOM y UTF-8 sin BOM).
- Algunos registros contienen espacios dobles y pequeños errores de digitación.

H. Identificación de problemas potenciales de calidad de datos

Los principales problemas de calidad identificados fueron:

- Desplazamiento de columnas en el Grupo B.
- Diferencias estructurales entre ambos grupos de archivos.
- Fusión de los nombres del supervisor y director en una sola variable.
- Existencia de una columna completamente vacía.
- Teléfonos con formatos inconsistentes.
- Diferentes formatos para la variable DISTRITO.
- Valores faltantes en variables importantes como PLAN, JORNADA, DIRECTOR, DIRECCION y TELEFONO.
- Diferencias en la acentuación y escritura de algunas variables.

Plan de limpieza

Variable	Problemas encontrados	Regla de limpieza	Justificación	Riesgos
CODIGO	No presenta problemas de formato ni duplicados.	Mantener sin cambios.	Es una llave única válida para identificar registros.	Ninguno.
DISTRITO	Dos formatos distintos y algunos códigos truncados.	Estandarizar todos los códigos al mismo formato y revisar manualmente los truncados.	Facilita el análisis y evita inconsistencias.	Asignar un distrito incorrecto si se corrige mal.
DEPARTAMENTO	Diferencias en el uso de tildes entre archivos.	Unificar la escritura siguiendo un solo criterio.	Mejora la consistencia del conjunto de datos.	Cambiar nombres oficiales si no se verifica.
MUNICIPIO	Sin problemas importantes.	Mantener la información y revisar únicamente errores	Conserva la información original.	Mínimos.

		ortográficos evidentes.		
ESTABLECIMIENTO	Valores faltantes, espacios dobles y algunos registros mezclados con la dirección.	Eliminar espacios dobles y revisar manualmente los registros afectados.	Mejora la calidad sin modificar nombres oficiales.	Alterar el nombre oficial del establecimiento.
DIRECCION	Valores faltantes y datos mezclados con otros campos.	Corregir únicamente cuando exista evidencia suficiente; mantener nulos cuando no sea posible recuperar el dato.	Evita introducir información incorrecta.	Separación errónea de los datos.
TELEFONO	Valores faltantes, números incompletos y múltiples teléfonos en una misma celda.	Separar teléfonos en columnas independientes y validar que tengan ocho dígitos.	Facilita la validación y el análisis.	Pérdida de algún número al separar la información.

SUPERVISOR / DIRECTOR	Valores faltantes y nombres fusionados en el grupo B.	Convertir “—” en valores nulos y mantener los nombres fusionados cuando no sea posible separarlos correctamente.	Evita crear datos incorrectos.	No poder recuperar ambos nombres por separado.
NIVEL	Todos los registros contienen el mismo valor.	Mantener la variable o documentarla como constante.	No requiere limpieza.	Ninguno.
SECTOR, AREA, STATUS, MODALIDAD, JORNADA y PLAN	Valores faltantes y categorías desplazadas en algunos registros.	Recuperar la información desde la columna DEPARTAMENTAL y estandarizar categorías.	Restablece la estructura original del conjunto de datos.	Clasificar incorrectamente algunos registros.
DEPARTAMENTAL	Contiene información de otras variables debido al desplazamiento de columnas.	Extraer la jurisdicción departamental y redistribuir la información a las columnas correspondientes.	Es el principal problema de calidad identificado.	Errores durante la separación automática de los datos.

